

Universidad Nacional Autónoma de México



Facultad de Ingeniería Ingeniería en computación

Inteligencia Artificial (406)

Profesor: Ing. Jorge Alberto
Hernández Nieto
Semestre 2025-1

Práctica 3. Red Neuronal

Grupo: 5

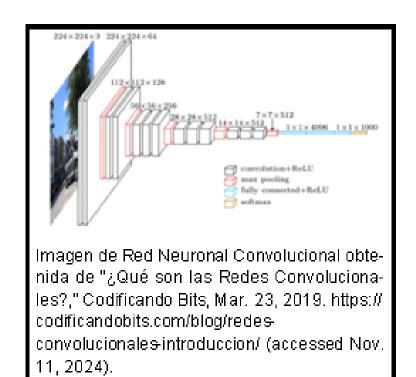
Integrantes del Equipo:

Bravo Luna Ivonne Monserrat
Cruz Maldonado Armando
Diaz Gonzalez Rivas Angel Iñaqui
Olivos Jiménez Luis Mario
Siliano Haller Rodrigo
Zarco Romero José Alberto



Índice o contenido

1. Objetivo	2
2. Introducción	2
3. Desarrollo	3
3.1. Red Neuronal. Ejercicio propuesto	3
3.1.1. Código	4
3.1.2. Captura de la Ejecución	12
4. Conclusiones	
5. Bibliografía / Referencias electrónicas	14



1. Objetivo

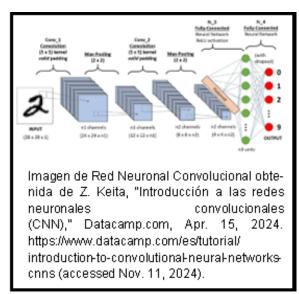
El estudiante desarrollará un sistema de análisis automatizado mediante redes neuronales que permita identificar y clasificar especies de animales en peligro de extinción a partir de videos, por medio de un software de extracción de fotogramas (como VLC) y técnicas de visión por computadora, se busca extraer imágenes clave de los videos, procesarlas e implementarlas en una red neuronal convolucional (CNN) para reconocer dichas especies. Al finalizar, se obtendrá un registro detallado de las especies identificadas.

2. Introducción

Una red neuronal es un método de la inteligencia artificial que enseña a las computadoras a procesar datos de una manera similar a como lo hace el cerebro humano. Se trata de un tipo de proceso de machine learning llamado aprendizaje profundo, el cual utiliza los nodos o las neuronas interconectados en una estructura de capas que se parece al cerebro humano. [1]

Las redes neuronales pueden ayudar a las computadoras a tomar decisiones inteligentes con asistencia humana limitada. Esto se debe a que pueden aprender y modelar las relaciones entre los datos de entrada y salida que no son lineales y que son complejos. [1]

Las redes neuronales se basan en datos de entrenamiento para aprender y mejorar su precisión con el tiempo. Una vez que se ajustan para obtener



precisión, son herramientas poderosas en informática e inteligencia artificial, lo que nos permite clasificar y agrupar datos a alta velocidad. [2]

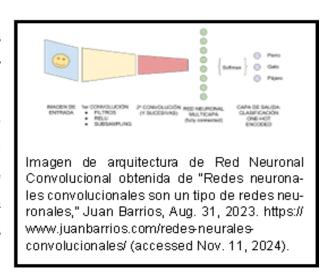
Las redes neuronales son muy útiles para, a partir de un dato de entrada, hacer una clasificación o regresión a partir de un modelo entrenado. Esta misma idea se puede aplicar a una imagen, para obtener su clasificación o detectar un objeto que forme parte de ella. Para ello se recurre a las redes neuronales convolucionales (CNN), las cuales han supuesto una revolución en el sector del reconocimiento de imágenes, ya que usan un procesamiento relativamente pequeño. [3]

En esta práctica, se utilizará una red neuronal convolucional para analizar un video mediante la extracción de imágenes clave o fotogramas con el software VLC. A partir de estos fotogramas, se buscará identificar y clasificar especies de animales en peligro de extinción. Este proceso permitirá explorar el uso de redes neuronales en la clasificación de imágenes y su potencial para el monitoreo de la biodiversidad, creando un registro de los animales detectados en el video y contribuyendo a la preservación de la fauna en riesgo.

3. Desarrollo

3.1. Red Neuronal. Ejercicio propuesto

Utilizando los fotogramas extraídos, se propone entrenar y ajustar una red neuronal para que, a partir de cada imagen, identifique las especies en peligro de extinción que aparezcan. Los resultados se registrarán y se visualizará la aparición de los animales detectados.



3.1.1.Código

Importación de librerías

♣ Carga del set de imágenes

```
Cargar set de Imágenes

dirmame = os.path.join(os.getcod(), 'animates')
inages = []
directories = []
directories = []
directories = []
directories = []
prevMoot=''
cant=0

print("leyendo inagenes de ",imppath)

for root, dirmames, filenames in os.walk(imppath);
for filename in filenames:
    if ro.search("\"\fipg)jpeg)jpeg)png|bmp|tiff)s", filename):
    cant=cant=!
    filename in, internames in filename)
    images.papend(image)
    b = "leyendo..." * str(cant)
    print("to, end="\r")
    if prevento: i=root:
        print(rost, cant)
        print(rost, cant)
        print(rost, cant)
        print(rost, cant)
        prevento: i=root:
        dircount.append(cant)
        dircount.append(cant)
        dircount.append(cant)

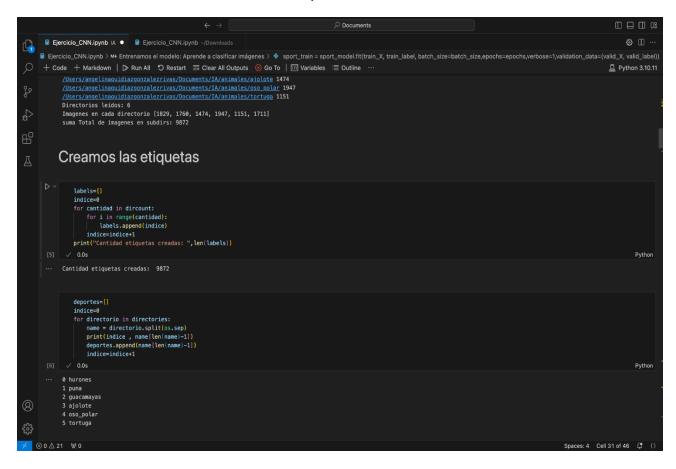
dircount = dircount[i]:
dircount(a)=dircount[i]:
dircount(a)=dircount[i]:
dircount(a)=dircount[i]:
print("birectories leidos:',len(directories))
print("loirectories leidos:',len(directories))
print("simagenes en cada directorio", dircount)

print("simagenes en cada directorio", dircount)
print("simagenes en cada directorio", dircount)

print("simagenes en cada directorio", dircount)
print("simagenes en cada directorio", dircount)

print("simagenes en cada directorio", dircount)
print("simagenes en cada directorio", dircount)
print("simagenes en cada directorio", dircount)
```

Creación de las Etiquetas



Creación de sets de entrenamiento y Test

```
y = np.array(labels)
import cv2
images_resized = [cv2.resize(img, (128, 128)) for img in images]  # Redimensionar a 128x128

X = np.array(images_resized, dtype=np.uint8)

# Find the unique numbers from the train labels
classes = np.unique(y)
nclasses = len(classes)
print('Total number of outputs : ', nclasses)
print('Output classes : ', classes)

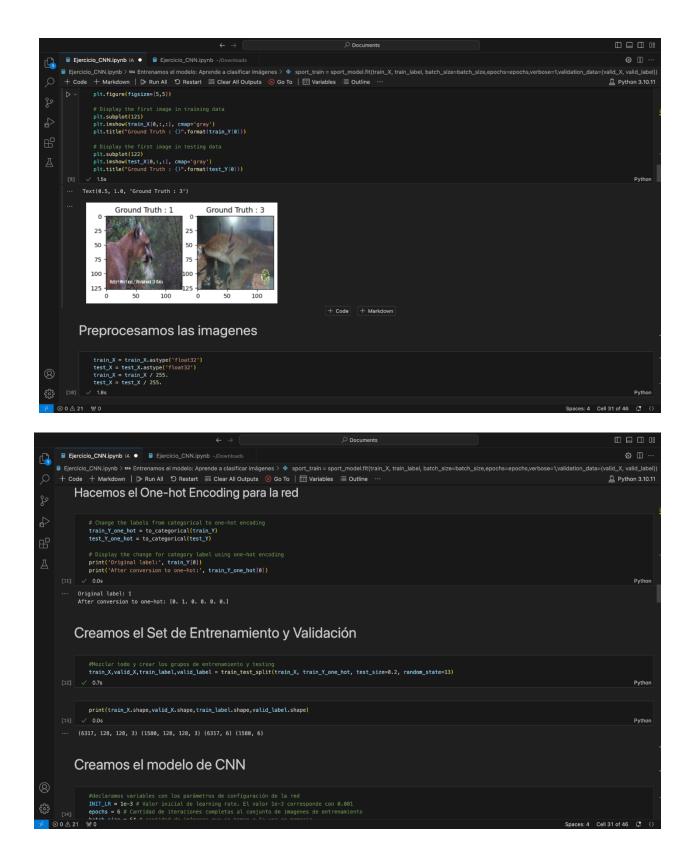
Total number of outputs : 6
Output classes : [8 1 2 3 4 5]

Creamos Sets de Entrenamiento y Test

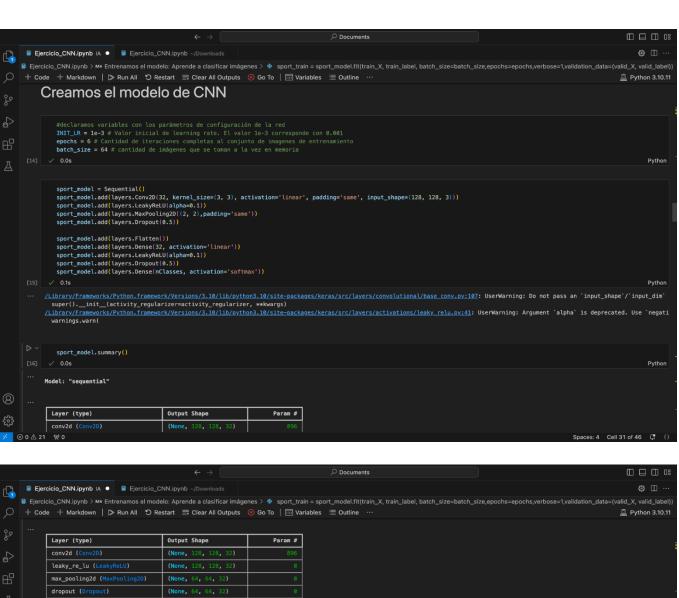
train_X,test_X,train_Y,test_Y = train_test_split(X,y,test_size=0.2)
print('Training data shape : ', train_X,shape, train_Y,shape)
print('Testing data shape : ', test_X.shape, test_Y.shape)

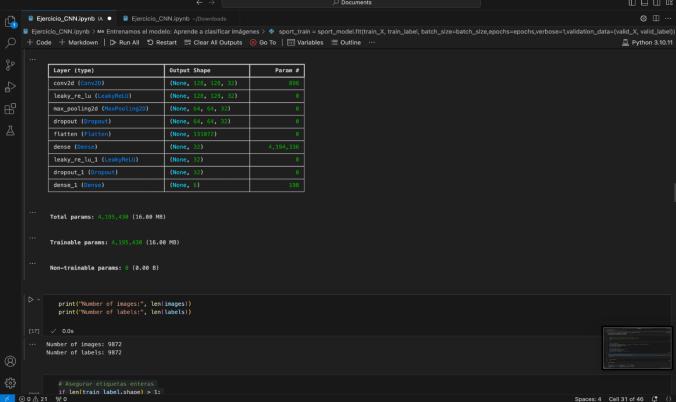
### Python

Training data shape : (7897, 128, 128, 3) (7897,)
Training data shape : (1975, 128, 128, 3) (1975,)
```

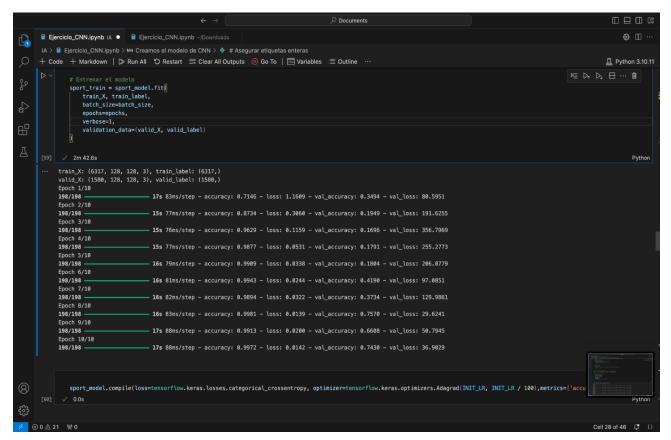


Creación del modelo de CNN

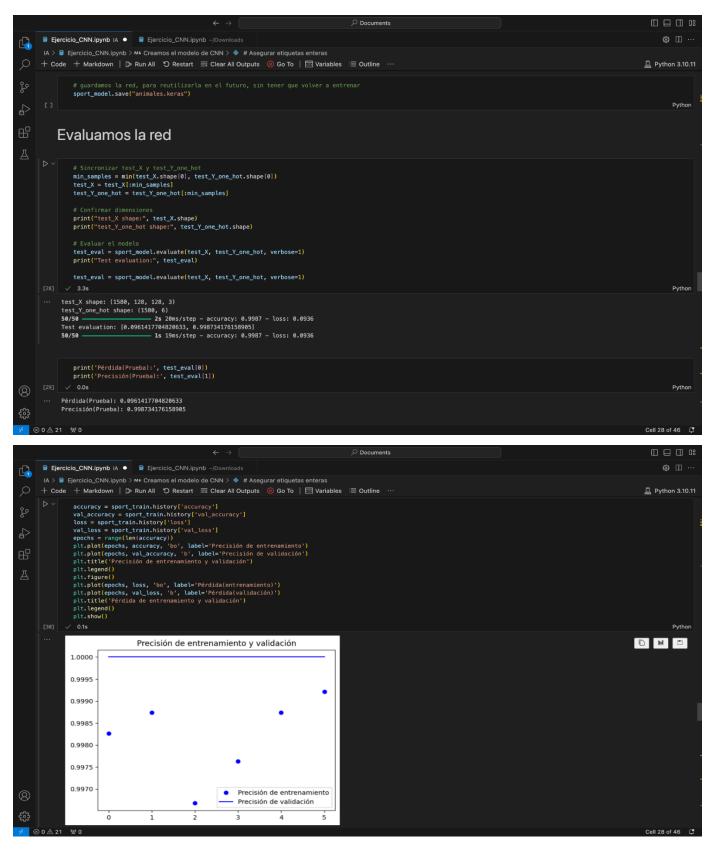


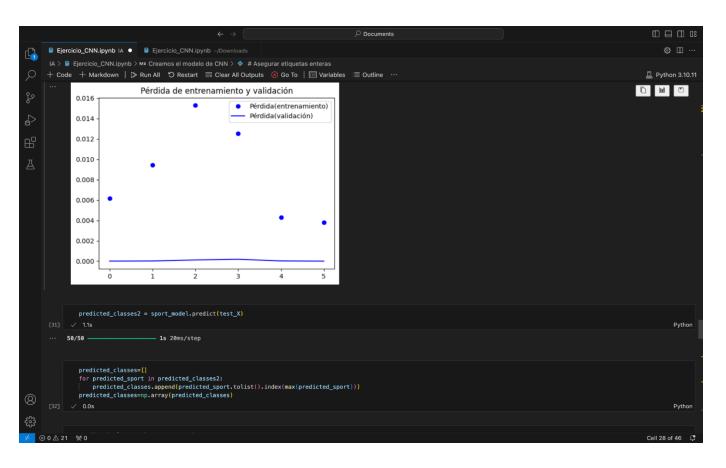


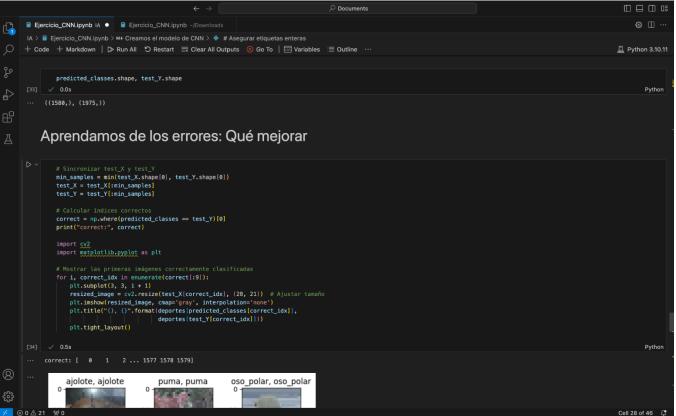
```
■ Ejercicio_CNN.ipynb IA • ■ Ejercicio_CNN.ipynb ~/Download:
                                                                                                                                                                                                                                           ⇔ ⊞ …
+ Code + Markdown | ▶ Run All り Restart ≡ Clear All Outputs ⊗ Go To |  Variables ≡ Outline
                                                                                                                                                                                                                                     Python 3.10.11
          # Asseyora etupeteas enteres
if lenitrain_label.shape) > 1:
    train_label = np.argmax(train_label, axis=1)
if lenivalid_label.shape) > 1:
    valid_label = np.argmax(valid_label, axis=1)
           # Configurar el modelo
sport_model.compile(
                 optimizer='adam'.
                loss=tensorflow.keras.losses.SparseCategoricalCrossentropy(from_logits=False),
metrics=['accuracy']
           print(f"train_X: {train_X.shape}, train_label: {train_label.shape}")
print(f"valid_X: {valid_X.shape}, valid_label: {valid_label.shape}")
           # Entrenar el modelo
sport_train = sport_model.fit()
    train_X, train_label,
    batch_size=batch_size,
                 epochs=epochs,
                 verbose=1,|
validation_data=(valid_X, valid_label)
      train_X: (6317, 128, 128, 3), train_label: (6317,)
valid_X: (1580, 128, 128, 3), valid_label: (1580,)
       Epoch 1/10
                                            • 17s 83ms/step - accuracy: 0.7146 - loss: 1.1609 - val_accuracy: 0.3494 - val_loss: 80.5951
       Epoch 2/10
      198/198 —
Epoch 3/10
                                          — 15s 77ms/step - accuracy: 0.8734 - loss: 0.3060 - val_accuracy: 0.1949 - val_loss: 191.6255
                                          — 15s 76ms/step - accuracy: 0.9629 - loss: 0.1159 - val accuracy: 0.1696 - val loss: 356.7969
       198/198 -
       Epoch 4/10
198/198
                                          - 15s 77ms/step - accuracy: 0.9877 - loss: 0.0531 - val_accuracy: 0.1791 - val_loss: 255.2773
       Epoch 5/10
                                             16s 79ms/step - accuracy: 0.9909 - loss: 0.0338 - val_accuracy: 0.1804 - val_loss: 206.0779
        Epoch 6/10
       198/198 -
                                          — 16s 81ms/step - accuracy: 0.9943 - loss: 0.0244 - val_accuracy: 0.4190 - val_loss: 97.0851
```

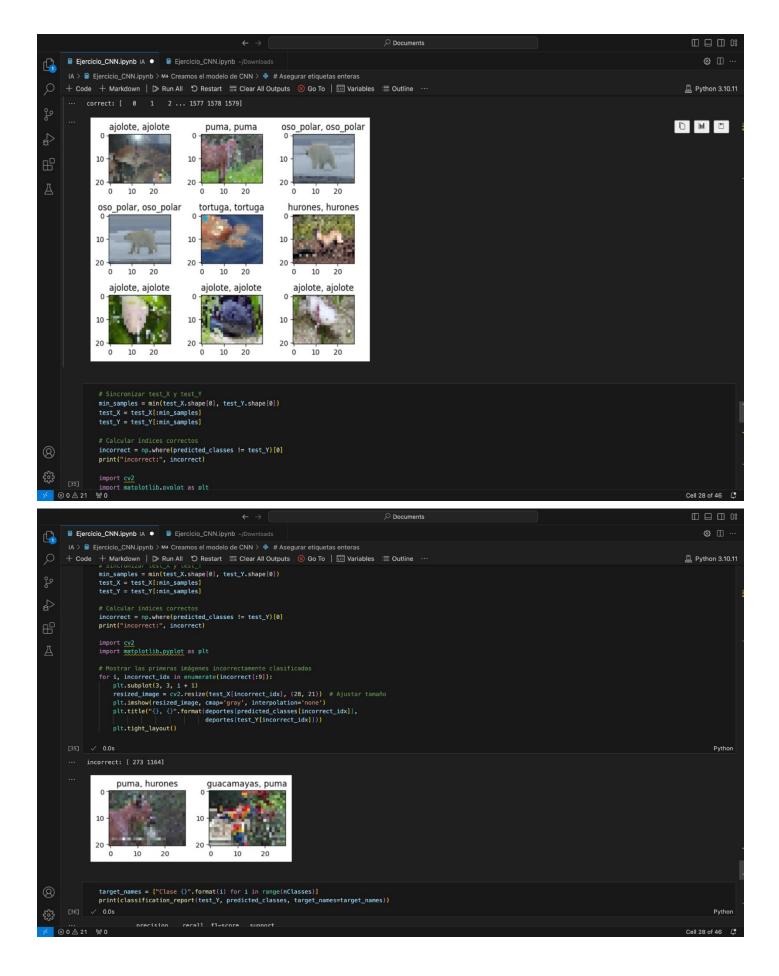


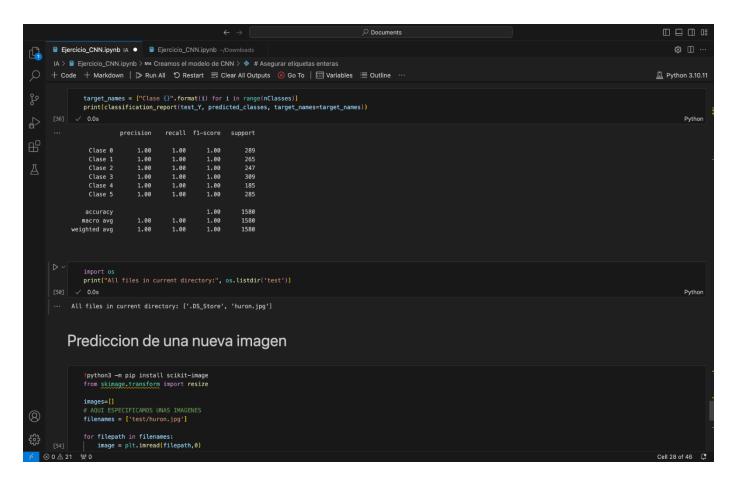
Evaluación de la red



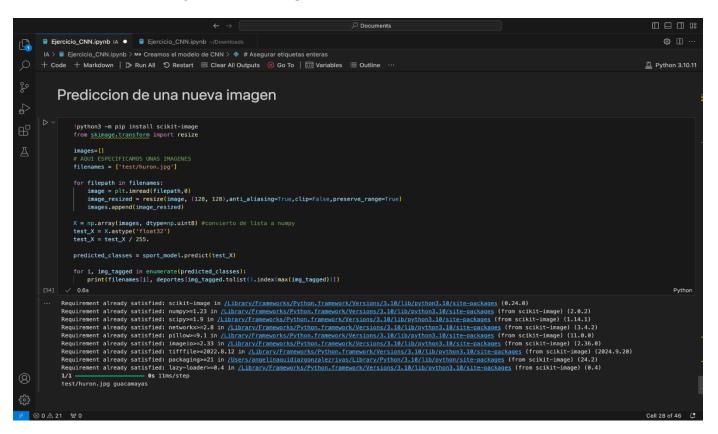








3.1.2. Captura de la Ejecución



4. Conclusiones

En conclusión, mediante la realización de esta práctica sobre redes neuronales convolucionales se demostró su aplicación en la identificación de animales en peligro de extinción por medio de imágenes extraídas de fotogramas con VLC, empleando técnicas de aprendizaje profundo que permiten a las computadoras reconocer patrones complejos en grandes volúmenes de datos visuales, como lo visto en clases teóricas.

Del mismo modo, La implementación de las redes neuronales convolucionales y el uso de modelos entrenados en imágenes de animales contribuye a la precisión en la detección, mientras que el análisis de resultados proporciona una base para futuras mejoras. Este proceso que se llevo a cabo permite procesar grandes volúmenes de datos visuales de manera rápida y eficiente, demostrando que las CNN son herramientas poderosas en tareas de clasificación y detección.

Finalmente, durante el desarrollo de esta práctica tuvimos algunos problemas en el desarrollo del código, puesto que era algo nuevo para nosotros el uso de esos programas, sin embargo, mediante una correcta organización e investigación pudimos cumplir satisfactoriamente con lo solicitado.

5. Bibliografía / Referencias electrónicas

- [1] "¿Qué es una red neuronal? Explicación de las redes neuronales artificiales AWS," Amazon Web Services, Inc., 2022. https://aws.amazon.com/es/what-is/neural-network/ (accessed Nov. 11, 2024).
- [2] IBM, "neural networks," Ibm.com, May 16, 2024. https://www.ibm.com/mx-es/topics/neural-networks (accessed Nov. 11, 2024).

[3] desarrollosidn, "Deep Learning: clasificando imágenes con redes neuronales | LIS Data Solutions," LIS Data Solutions, May 25, 2020. https://www.lisdatasolutions.com/es/blog/deep-learning-clasificando-imagenes-con-redes-neuronales/ (accessed Nov. 11, 2024).